GroupaIQ

Architecture Agentique — Cible V2 — Avril 2026

> Ce document présente l'**architecture cible** que le système GroupaIQ pourrait adopter : comment le POC actuel s'étendrait vers une plateforme d'entreprise intégrant **Microsoft Foundry (FoundryIQ)**, **Microsoft Agent Framework** (pro-code), des sources de données hétérogènes (SharePoint, SAP, systèmes on-premise), et optionnellement **Microsoft Fabric (FabricIQ)** pour l'unification des données.
>
> **Principe fondamental : les données restent là où elles sont.** L'architecture est conçue pour accéder aux données **in situ**, sans copie ni déplacement obligatoire. Fabric et OneLake sont des **accélérateurs optionnels**, pas des prérequis.
>
> Les intégrations décrites s'appuient sur des **connecteurs vérifiés dans la documentation Microsoft** (avril 2026). Les références à des systèmes spécifiques (SAP, Oracle, GED) sont données à titre d'**exemples représentatifs** et seraient à adapter selon le SI réel du client.
>
> Pour l'architecture POC actuelle, voir ARCHITECTURE-AGENTIC.md.

---

1. Vue d'ensemble — Architecture cible

L'architecture cible reposerait sur **trois couches** qui s'empilent naturellement : les **sources de données** alimenteraient la **couche agentique (FoundryIQ)** pour produire des décisions. La **plateforme de données (FabricIQ)** est un **accélérateur optionnel** qui ajouterait unification, gouvernance et ontologie métier — mais **n'est pas un prérequis**.

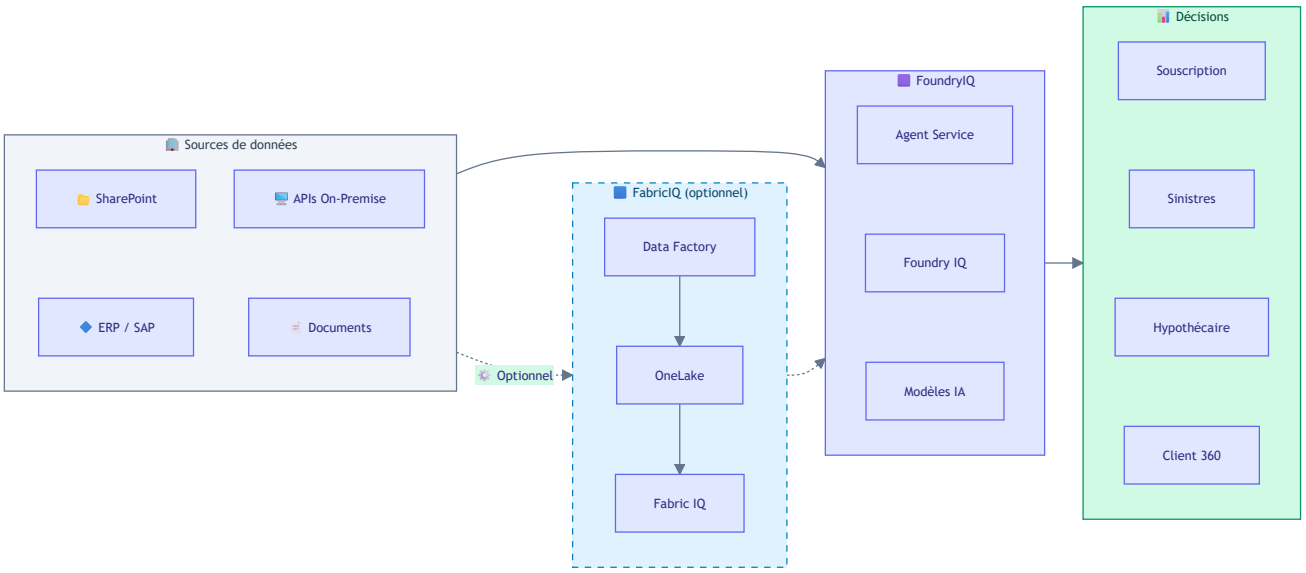

Couche	Rôle	Produit Microsoft	Obligatoire ?
Sources	Les données brutes **restent là où elles sont**	SharePoint, ERP, APIs on-premise, bases relationnelles, documents	—
FabricIQ	Unifierait, nettoierait et gouvernerait les données	Microsoft Fabric (Data Factory + OneLake + IQ)	⚠️ **Optionnel**
FoundryIQ	Agents IA qui raisonneraient sur les données	Microsoft Foundry (Agent Service + IQ + Modèles)	✅ **Requis**
Décisions	Résultats métier traçables pour chaque persona	Dashboards GroupalQ + rapports PDF	✅ **Requis**

> 💡 **Les données ne bougent pas.** Foundry IQ et les agents Foundry accèdent directement aux données via **Azure AI Search**, **Azure Blob Storage**, **SharePoint**, **MCP Servers** et **APIs REST** — sans qu'il soit nécessaire de copier quoi que ce soit dans OneLake. Fabric intervient uniquement si le client souhaite une **couche d'unification et d'ontologie métier** supplémentaire.

---

2. Sources de données — Connecteurs vérifiés

Ce diagramme détaille **comment chaque type de source de données** pourrait rejoindre la plateforme. Les connecteurs listés sont **documentés et supportés par Microsoft** ; les systèmes spécifiques (SAP, Oracle, etc.) sont donnés à titre d'exemple et dépendraient du SI réel.

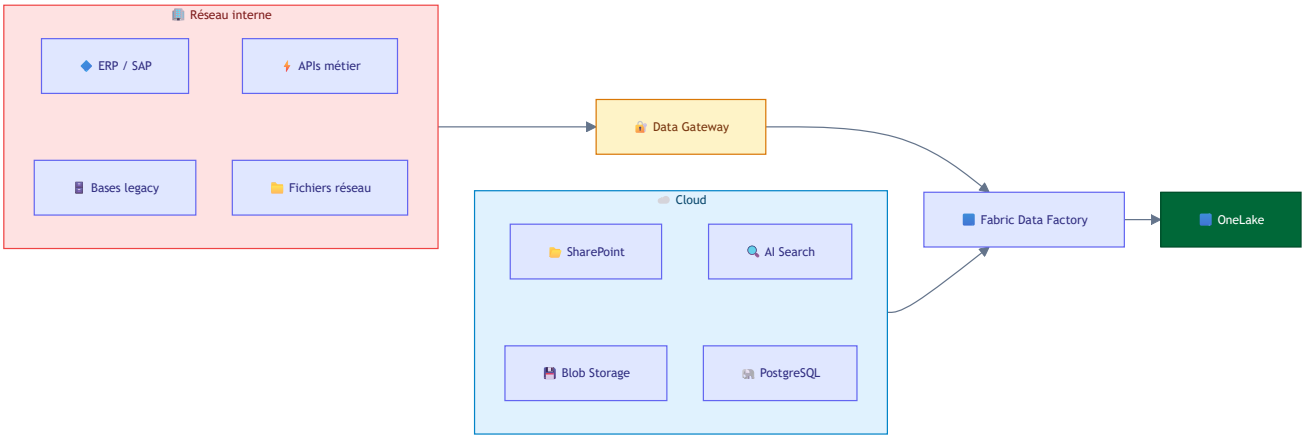

Connecteurs SAP vérifiés dans Fabric Data Factory

> Les connecteurs ci-dessous sont documentés par Microsoft. Leur utilisation dépendrait de la présence effective de SAP dans le SI du client.

Connecteur	Mode	Passerelle	Authentification
SAP HANA	Dataflow Gen2, Pipeline, Copy Job	On-premises	Basic, Windows
SAP BW Application Server	Dataflow Gen2	On-premises	Basic, Windows
SAP BW Message Server	Dataflow Gen2	On-premises	Basic
SAP Table Application Server	Pipeline, Copy Job	Avec ou sans	Basic
SAP Table Message Server	Pipeline, Copy Job	Avec ou sans	Basic
SAP CDC (via ADF)	Incrémental (delta)	Azure Data Factory	ODP Framework

Autres connecteurs on-premise confirmés

> Cette liste couvre les connecteurs les plus courants dans le secteur de l'assurance. Les sources effectivement présentes dépendraient du SI en place.

Source	Type	Passerelle requise
Oracle Database	Relationnelle	Oui
SQL Server	Relationnelle	Oui
IBM Db2	Relationnelle	Oui
MySQL / PostgreSQL	Relationnelle	Oui
OData	API REST	Oui
ODBC / OLE DB	Générique	Oui
Fichiers / Dossiers	Système de fichiers	Oui
Teradata / Sybase	Relationnelle	Oui

---

3. FabricIQ — Plateforme de données unifiée (optionnel)

Microsoft Fabric **pourrait** centraliser les données dans OneLake et exposer des capacités intelligentes via **Fabric IQ** (preview). Cependant, **Fabric n'est pas un prérequis** pour faire fonctionner la couche agentique.

> 🔑 **Données in situ** : même avec Fabric, les données peuvent rester à leur emplacement d'origine grâce aux **OneLake Shortcuts** — des références virtuelles (zero-copy) vers Azure Data Lake Storage, Amazon S3, Google Cloud Storage ou d'autres workspaces Fabric. **Aucune copie de données n'est nécessaire.** Les moteurs Fabric (Spark, SQL, Power BI) interrogent les données à travers les shortcuts comme si elles étaient locales. *(Source : OneLake Shortcuts — Microsoft Learn)*

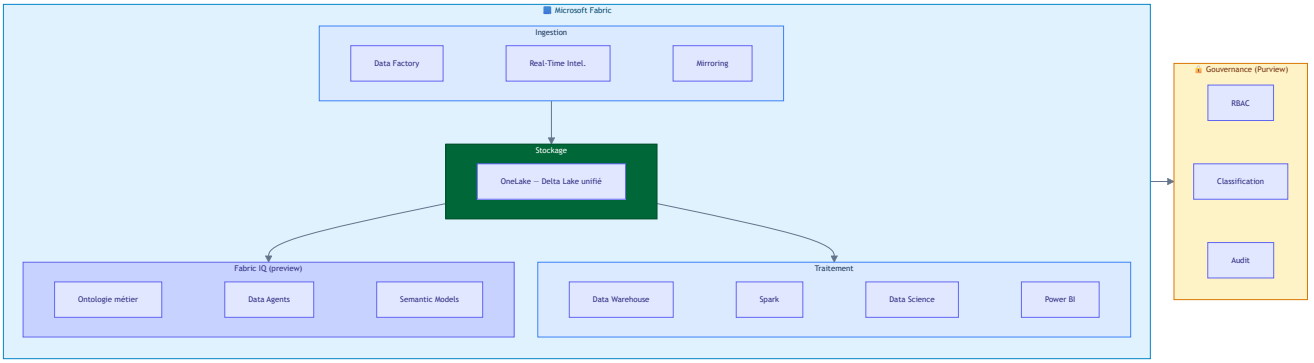

Fabric IQ (preview avril 2026) apporterait :

- **Ontologie** : définitions métier standardisées (« sinistre », « prime », « assuré ») partagées entre les agents
- **Data Agents** : interrogation des données en langage naturel, sans écrire de SQL
- **Semantic Models** : métriques et KPIs réutilisables et gouvernés dans toute l'organisation
- **Fabric Graph** : relations entre entités métier pour le raisonnement contextuel

---

4. FoundryIQ — Couche agentique

Microsoft Foundry **orchestrerait les agents IA** qui raisonnent sur les données unifiées par Fabric.

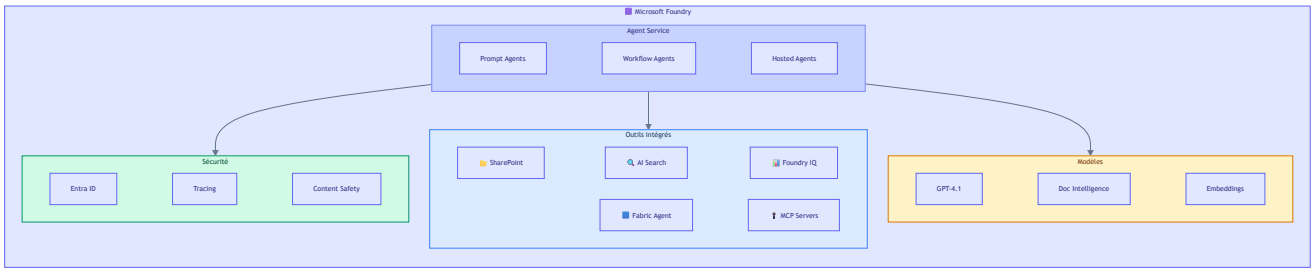

Outils Foundry vérifiés pour un contexte assurance

Outil	Statut	Usage potentiel
SharePoint	Preview (GA prévue 2026)	Accès aux polices et pièces dans SharePoint, avec SSO (OBO)
Azure AI Search	GA	Index sémantique des Conditions Générales (remplacerait pgvector à terme)
Foundry IQ	GA	Knowledge bases clé en main pour le grounding RAG des agents
Fabric Data Agent	Preview	Interrogation OneLake : données ERP, contrats, historique sinistres
MCP Servers	Preview	Pont vers les APIs REST on-premise (SI métier, GED, tarificateurs)
Code Interpreter	GA	Calculs financiers complexes (ratios GDS/TDS/LTV)
Web Search	✅ GA (avril 2026)	Enrichissement externe (cours immobilier, cotes véhicules), citations inline

---

5. APIs métiers On-Premise — Stratégie de connexion

Les systèmes métier internes seraient accessibles via **deux chemins complémentaires** selon le type d'accès requis.

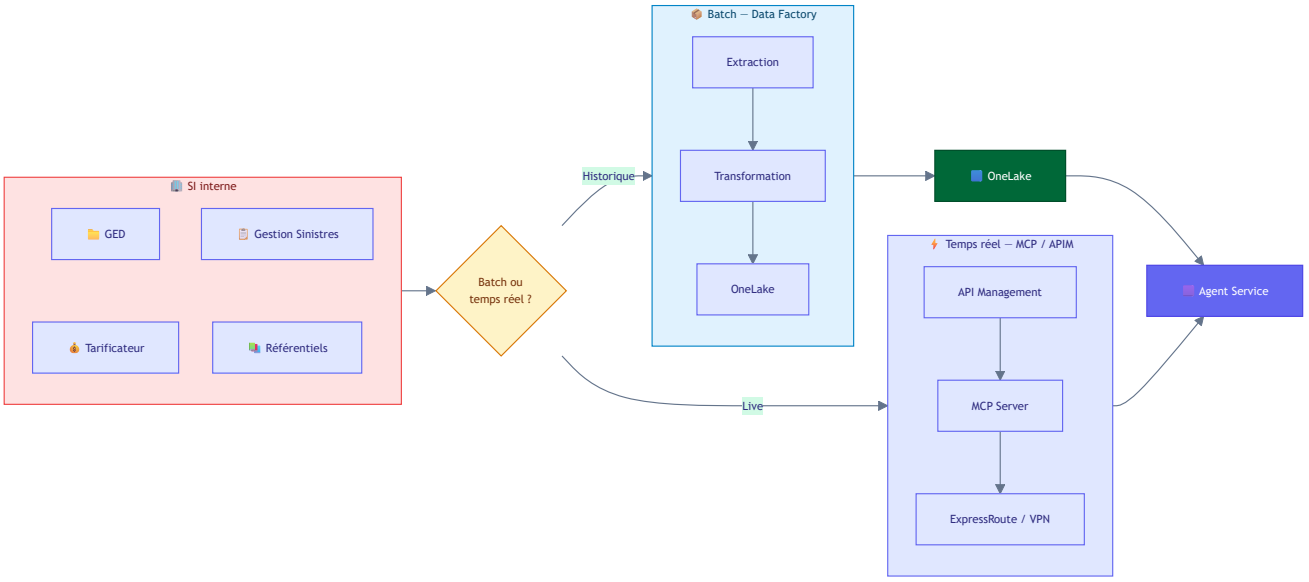

Exemples d'intégration (selon le SI en place)

Système (exemple)	Chemin	Méthode	Usage potentiel
ERP / SAP	Batch	Data Factory → connecteur SAP → OneLake	Données contractuelles pour Client 360
GED	Temps réel	MCP Server → API REST GED	Agent Données récupère une pièce jointe à la volée
Tarificateur	Temps réel	APIM → API SOAP/REST interne	Agent Risque appellerait le tarificateur pour valider une prime
Gestion Sinistres	Batch + Live	Data Factory (historique) + MCP (statut)	Historique dans OneLake + statut temps réel
Référentiels	Batch	Data Factory → base relationnelle → OneLake	Barèmes, produits, garanties indexés par Fabric IQ
CRM	Batch	Data Factory → base relationnelle → OneLake	Fiche client complète pour Client 360

---

6. Architecture cible intégrée — Flux complet

Ce diagramme montre le **flux de bout en bout** envisagé : de la donnée brute à la décision, en passant par FabricIQ et FoundryIQ.

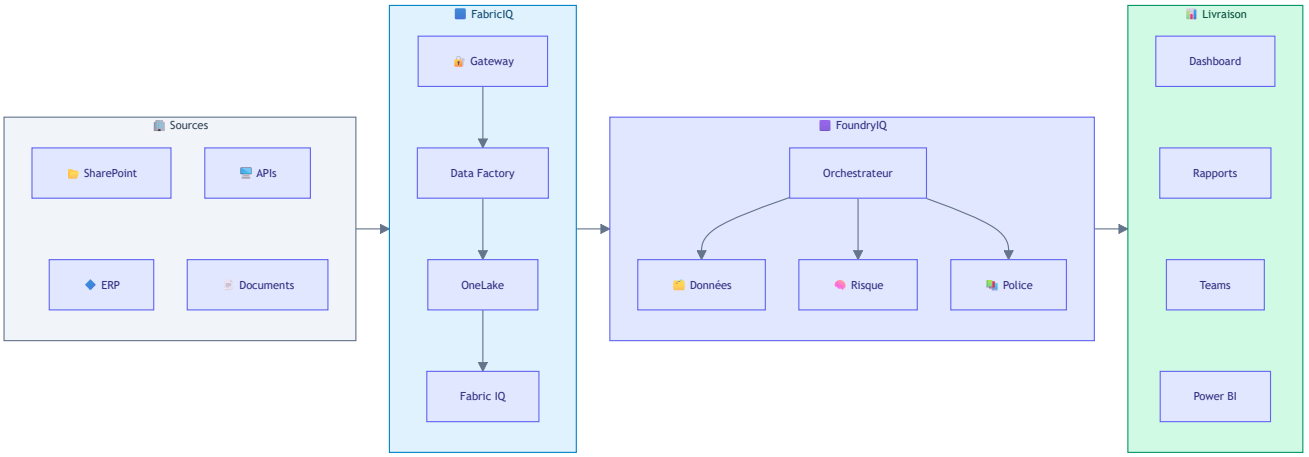

---

7. POC actuel vs Architecture cible

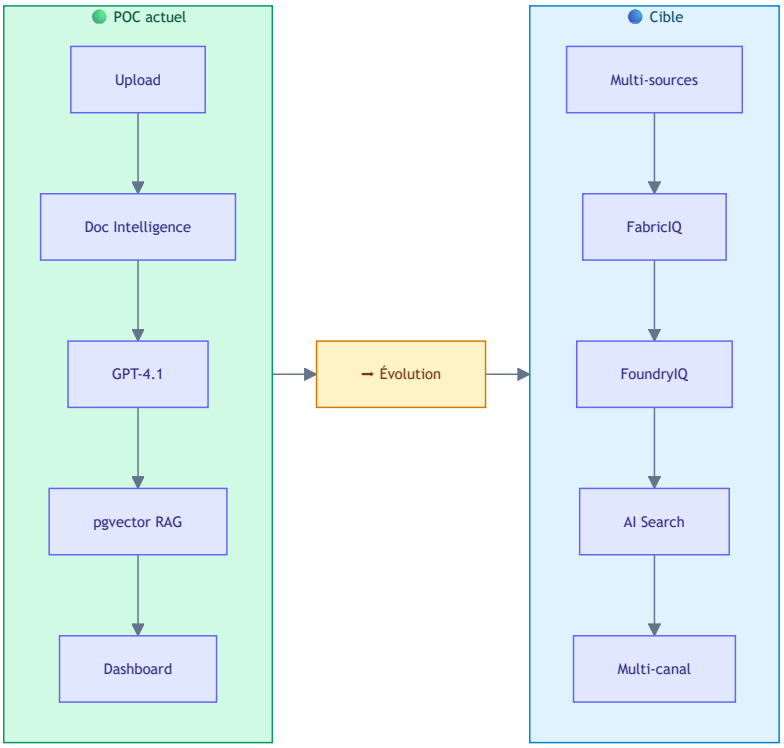

Composant	POC actuel	Architecture cible	Changement
Sources de données	Upload manuel de PDF/photos	ERP, SharePoint, GED, APIs on-premise, bases legacy	Multi-canal automatisé
Stockage	Azure Blob Storage	OneLake (Fabric) + Blob *ou* Blob + AI Search seuls	Lac unifié **ou** stockage existant
Recherche polices	PostgreSQL + pgvector	Azure AI Search + Foundry IQ	Scalable + managed
Orchestration agents	FastAPI custom Python	Foundry Agent Service (Workflow Agents)	Managed + observable
Modèle IA	Azure OpenAI (direct)	Foundry Model Catalog (même modèles)	Versioning + guardrails
Connecteurs métier	Aucun	Data Factory (batch) + MCP Servers (temps réel)	Intégration SI complète
Gouvernance	API Key manuelle	Entra ID + Purview + RBAC	Enterprise-grade
Livraison	Dashboard Next.js	Dashboard + Teams + Power BI	Multi-canal
Observabilité	Logs applicatifs	Application Insights + Agent Tracing	Bout en bout

8. Séquence cible — Traitement d'un sinistre auto

Ce diagramme montre le déroulement complet envisagé dans l'architecture cible, avec les sources multi-canaux et les outils Foundry.

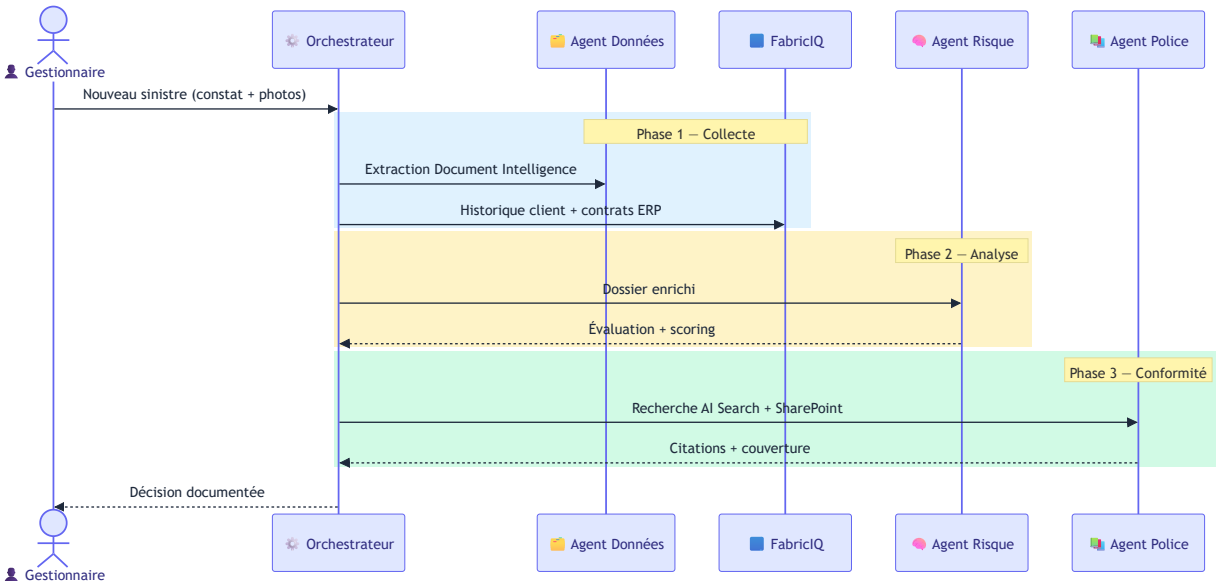

9. Matrice de faisabilité — Vérification technique

Chaque intégration est classée selon son **statut réel** dans l'écosystème Microsoft (avril 2026). Le niveau de complexité dépendrait du SI existant et de l'infrastructure réseau.

Intégration	Statut Microsoft	Complexité	Pré-requis
SharePoint → Foundry Agent	✅ Preview (built-in tool)	Faible	Licence M365 Copilot, Entra ID
Azure AI Search → Foundry Agent	✅ GA (built-in tool)	Faible	Resource AI Search déployée
Foundry IQ (knowledge retrieval)	✅ GA	Faible	Foundry project configuré
Fabric Data Factory → SAP HANA	✅ GA (connector)	Moyenne	Data Gateway on-premise installée
Fabric Data Factory → SAP BW	✅ GA (connector)	Moyenne	Data Gateway + config SAP
Fabric Data Factory → SAP Table	✅ GA (connector)	Moyenne	Avec ou sans gateway
SAP CDC (delta incrémental)	✅ GA (via ADF)	Élevée	ODP Framework SAP, licence SAP
Fabric Data Factory → Oracle/SQL	✅ GA (connector)	Faible	Data Gateway on-premise
Fabric IQ (ontologie, data agents)	🟡 Preview	Moyenne	Fabric capacity, IQ workload activé
Fabric Data Agent → Foundry	🟡 Preview	Moyenne	Fabric + Foundry liés
MCP Server custom (APIs on-premise)	🟡 Preview	Élevée	Développement MCP custom + APIM
Workflow Agents (multi-agents)	🟡 Preview	Moyenne	Foundry Agent Service
Hosted Agents (containers custom)	🟡 Preview	Élevée	Container Registry + code agent
OneLake Shortcuts (cross-cloud)	✅ GA	Faible	Comptes ADLS, S3 ou GCS
Publication dans Teams	✅ GA	Faible	Entra Agent Registry
Power BI sur OneLake	✅ GA	Faible	Fabric capacity

Légende : ✅ GA = Disponible en production | 🟡 Preview = Utilisable mais non garanti SLA

10. Chaîne de valeur — ROI de l'architecture cible

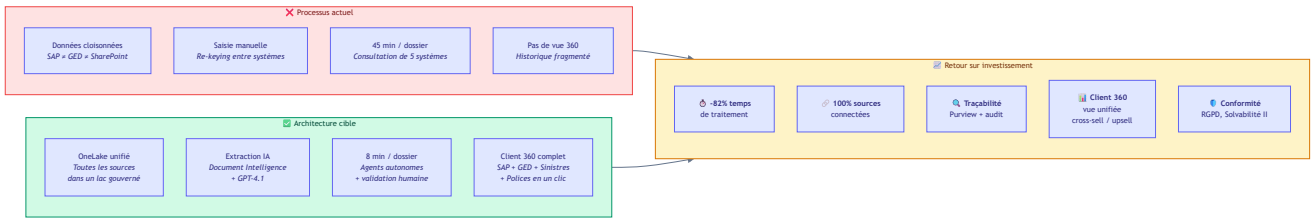

11. Microsoft Agent Framework — Pro-code pour workflows custom

Le POC GroupaIQ est actuellement implémenté en **FastAPI custom**. L'architecture cible pourrait migrer les agents vers **Microsoft Agent Framework SDK**, qui offre un runtime managé, de l'observabilité native, et une publication multi-canal.

> **Stratégie hybride** : l'architecture ne se limiterait pas à un seul framework. **Microsoft Agent Framework** et **LangChain / LangGraph** sont les deux piliers recommandés, combinables librement selon les workloads. Les agents peuvent être hébergés soit dans **Foundry Agent Service** (Hosted Agents), soit dans **Azure Container Apps** (ACA). Le choix dépendrait de la complexité du workflow, des compétences de l'équipe et des exigences d'intégration. Voir la **matrice de décision** en fin de section pour guider le choix par workload.

Trois niveaux d'agents Foundry

Stratégie agents par workflow

Workflow	Type d'agent envisagé	Justification	Outils connectés
Sinistres Habitation	Hosted Agent	Logique custom : scoring dommages, corrélation historique, photos multimodales	CU, GPT-4.1, AI Search, **Web Search**, MCP→GED
Sinistres Auto	Hosted Agent	Pipeline multimodale : analyse photos + constat + cotes via web search	CU, GPT-4.1, **Web Search**, Fabric Agent→ERP
Sinistres Santé	Workflow Agent	Flux standardisé : extraction facture → couverture → calcul	CU, AI Search, Code Interpreter
Souscription	Hosted Agent	Scoring complexe, APS médical multi-pages, deep dive	CU, GPT-4.1, AI Search, Fabric Agent
Hypothécaire	Workflow Agent + Code Interpreter	Calculs réglementaires GDS/TDS/LTV	CU, Code Interpreter, **Web Search**, AI Search
Client 360	Prompt Agent + Fabric Data Agent	Agrégation cross-persona, langage naturel	Fabric Agent→OneLake, SharePoint, AI Search

Exemple pro-code — Agent Sinistres Habitation

```
# Hosted Agent GroupaIQ — Microsoft Agent Framework SDK
from agent_framework import ai_function, ChatAgent
from agent_framework.azure import AzureAIAgentClient
from azure.ai.agentserver.agentframework import from_agent_framework

@ai_function
def evaluate_property_damage(claim_data: str, photos_analysis: str) -> str:
    """Évalue les dommages habitation en croisant extraction CU + analyse photos."""
    # Logique métier Groupama : barèmes, plafonds, exclusions
    ...

@ai_function
def search_market_value(address: str, surface_m2: float) -> str:
    """Recherche la valeur immobilière via données de marché."""
    # Appel API tarificateur ou données OneLake
    ...

agent = ChatAgent(
    chat_client=AzureAIAgentClient(
        project_endpoint=PROJECT_ENDPOINT,
        model_deployment_name="gpt-4.1",
        credential=DefaultAzureCredential(),
    ),
    instructions="""Vous êtes l'Agent Sinistres Habitation de Groupama.
    Analysez les déclarations de sinistre MRH en :
    1. Extrayant les champs structurés (Document Intelligence)
    2. Évaluant les dommages (photos + description)
    3. Vérifiant la couverture (Conditions Générales Habitation)
    4. Détectant les anomalies et indicateurs de fraude
    Produisez un rapport avec citations des articles applicables.""",
    tools=[evaluate_property_damage, search_market_value],
)

# Déploiement : conteneur Docker → ACR → Foundry Agent Service
if __name__ == "__main__":
    from_agent_framework(agent).run()  # localhost:8088 en dev
```

Connecteurs agents — Fabric, API, MCP et outils built-in

Les agents disposeraient de **trois familles de connexions** pour accéder aux données et aux services :

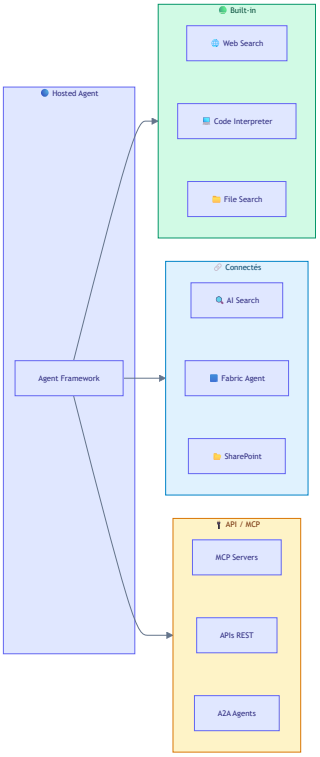

Type de connexion	Protocole	Usage	Exemple
Built-in tools	Natif Foundry	Outils intégrés au runtime, configuration sans code	Web Search, Code Interpreter, File Search
Azure AI Search	REST / SDK	Index sémantique managé pour le grounding RAG	Polices Groupama vectorisées
SharePoint	Graph API (OBO)	Accès documents métier avec identité utilisateur	Pièces justificatives, courriers
Fabric Data Agent	OneLake SDK	Interrogation données unifiées en langage naturel	Données ERP, historique sinistres
MCP Servers	Model Context Protocol	Pont standardisé vers APIs on-premise ou SaaS	GED, tarificateur, gestion sinistres
APIs REST custom	HTTP / APIM	Appels directs via Azure API Management	Référentiels internes, services tiers
A2A (Agent-to-Agent)	A2A Protocol	Communication inter-agents via endpoints standardisés	Orchestration multi-agents cross-domaine
OpenAPI tools	OpenAPI spec	Import automatique d'APIs depuis leur spécification	Toute API documentée en OpenAPI 3.x

Stratégie hybride — Liberté de choix par workload

L'architecture cible ne reposerait **pas sur un seul framework** mais sur une **approche hybride** permettant de combiner les outils les plus adaptés à chaque workload. Cette liberté de choix éviterait le verrouillage technologique et permettrait à chaque équipe de capitaliser sur ses compétences.

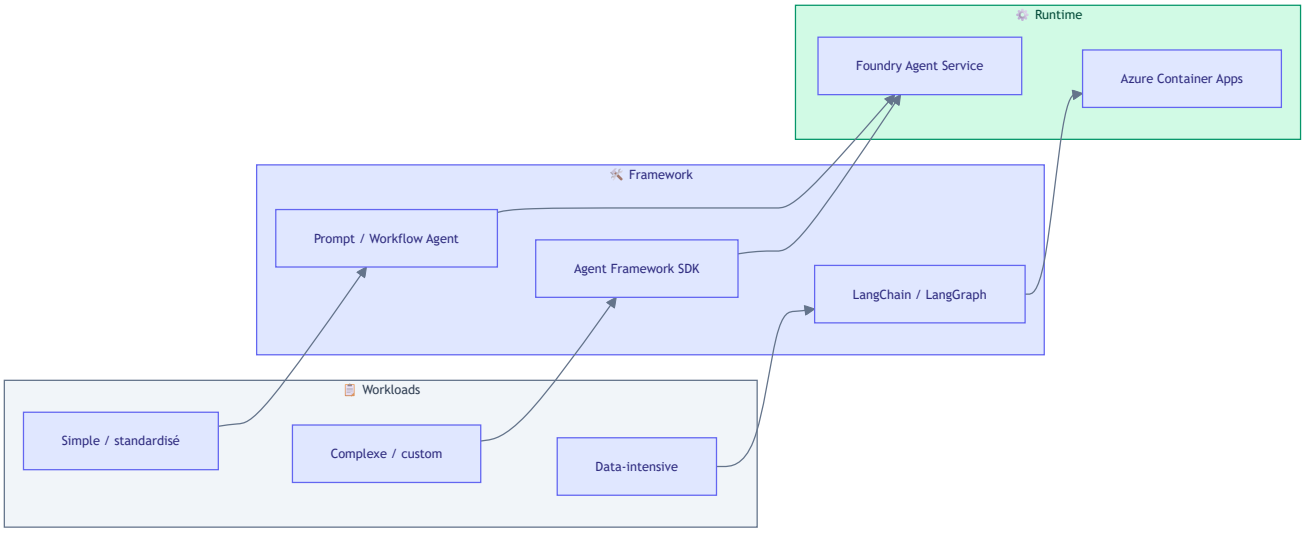

Matrice de décision — Quel framework pour quel workload ?

Critère	Prompt / Workflow Agent	Agent Framework SDK	LangChain / LangGraph
Complexité	Flux linéaires, règles simples	Logique métier custom, multi-outils	Graphs complexes, boucles, état riche
Compétences requises	No-code / low-code	Python / .NET	Python avancé
Gouvernance Foundry	✅ Natif portal	✅ Hosted Agent managé	⚠️ Via ACA + APIM
Observabilité	✅ Traces Foundry natives	✅ OpenTelemetry intégré	✅ LangSmith / App Insights
Évaluation	✅ Foundry Evaluation	✅ Foundry Evaluation	⚠️ LangSmith ou custom
Multi-agent	✅ Workflow YAML natif	✅ Agent-to-Agent (A2A)	✅ LangGraph natif
Écosystème outils	Built-in Foundry	@ai_function custom	700+ intégrations LangChain
Distribution M365	✅ Agents 365, Teams	✅ Via Agent Registry	⚠️ Via API custom
Portabilité	⚠️ Foundry only	⚠️ Azure-centric	✅ Multi-cloud

Scénarios hybrides recommandés pour l'assurance

Scénario	Combinaison recommandée	Justification
Sinistres Auto (photos + constat + cotes)	Agent Framework SDK (orchestration) + LangGraph (graph de décision fraude)	L'orchestration multimodale se fait en Agent Framework ; la détection de fraude nécessite un graph complexe avec boucles de vérification
Sinistres Habitation (expertise + historique)	Agent Framework SDK uniquement	Workflow custom suffisant, bénéfice maximal de l'écosystème Foundry (tracing, évaluation)
Souscription (APS médical)	Agent Framework SDK + Code Interpreter	Scoring complexe avec calculs réglementaires, deep dive médical
Client 360 (agrégation)	Prompt Agent (Fabric Data Agent) + Agent Framework (enrichissement)	Requêtes naturelles sur OneLake via Prompt Agent, enrichissement par un Hosted Agent
Recherche polices RAG	LangChain (retrieval) + Agent Framework (agent)	LangChain excelle pour les pipelines RAG complexes (re-ranking, hybrid search) ; le résultat alimente un agent Foundry
Chatbot Teams	Prompt Agent Foundry	Cas standard, no-code, distribution native Teams/M365

Comment choisir — Arbre de décision

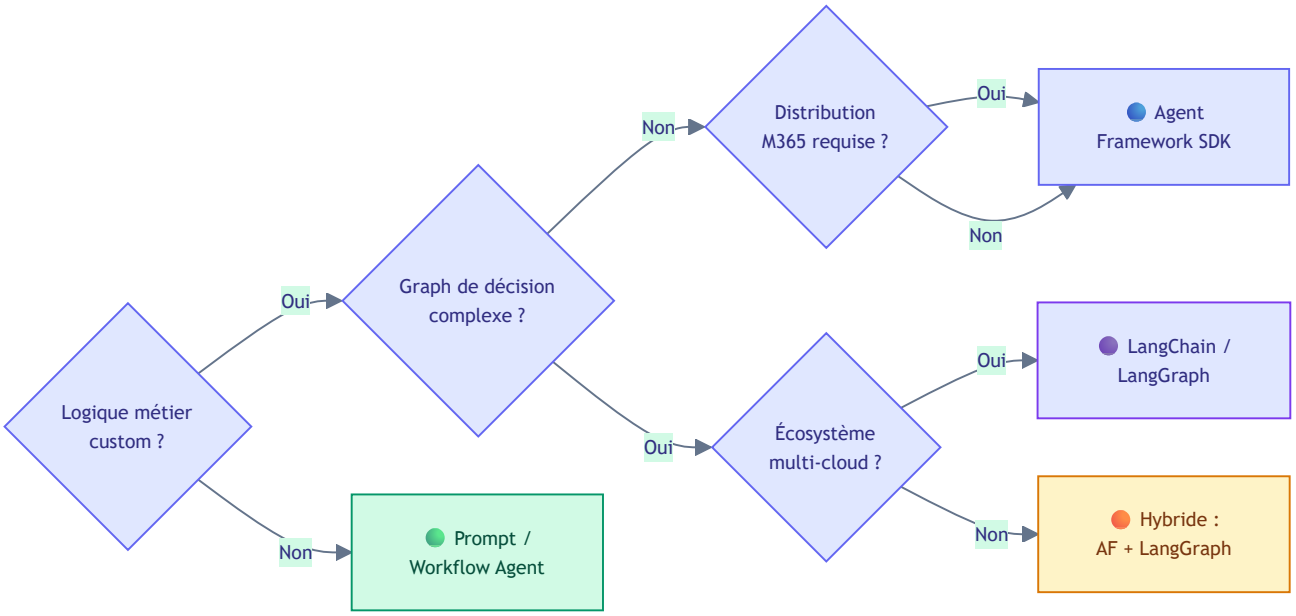

> **Clé** : la plupart des workloads d'assurance se satisferaient de **Microsoft Agent Framework SDK** pour bénéficier de la gouvernance Foundry native. **LangChain / LangGraph** serait privilégié pour les graphs de décision complexes (fraude, multi-vérification) ou lorsque la portabilité multi-cloud est requise. Les deux cohabitent dans la même architecture via **ACA** ou **Foundry Agent Service**.

12. Gouvernance des agents — Sécurité, identité et contrôle

Le déploiement d'agents IA en entreprise nécessiterait un **cadre de gouvernance robuste**. L'écosystème Microsoft propose un **control plane unifié** qui couvrirait l'identité, la sécurité, la distribution et l'observabilité des agents.

Architecture de gouvernance

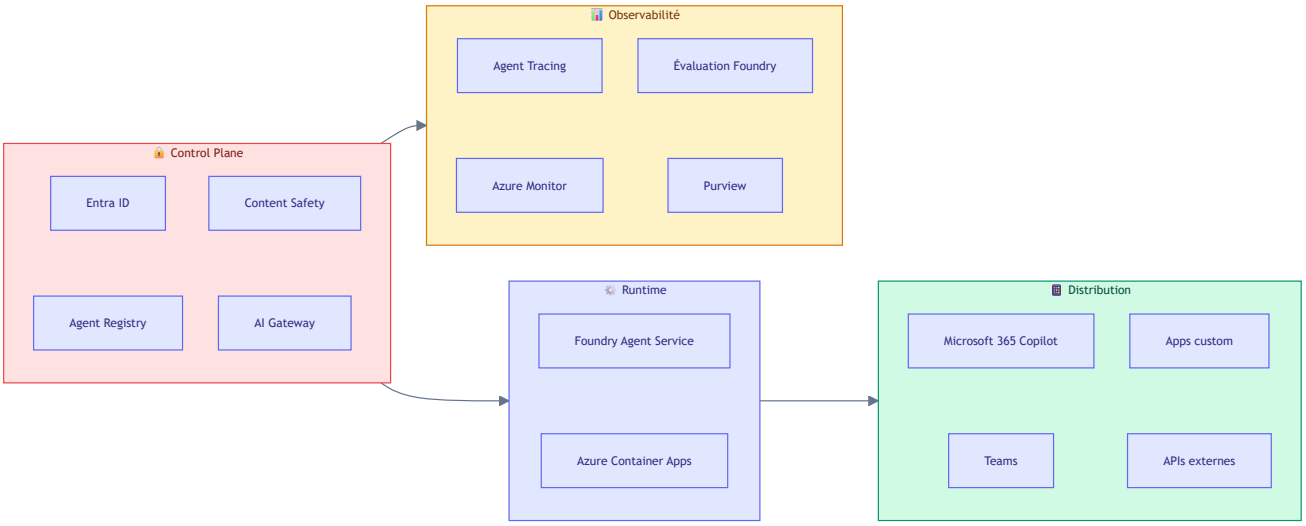

Entra ID — Identité par agent

Chaque agent disposerait de sa propre **identité managée** dans Microsoft Entra ID :

Capacité	Description
Managed Identity	Chaque agent possède une identité système ou utilisateur — pas de secrets partagés
OBO (On-Behalf-Of)	L'agent agit avec les droits de l'utilisateur final, pas un compte technique
RBAC granulaire	Permissions par agent : quel agent accède à quelles données, quels outils
Conditional Access	Politiques d'accès conditionnel applicables aux agents (géo, device, risk level)
Audit logs	Chaque action d'agent tracée dans Entra ID audit logs

Entra Agent Registry — Publication et découverte

L'**Entra Agent Registry** centraliserait l'enregistrement et la distribution des agents :

Fonction	Description
Enregistrement	Chaque agent publié dans un registre centralisé avec métadonnées (nom, description, capabilities)
Découverte	Les utilisateurs et applications découvrent les agents disponibles via le registre
Consentement	Workflow d'approbation admin avant qu'un agent soit accessible aux utilisateurs
Distribution M365	Agents publiés dans Microsoft 365 Copilot, Teams, Outlook via le registre
Agents 365	Les agents enregistrés deviennent invocables comme « Agents 365 » dans l'écosystème Copilot

Azure AI Gateway (APIM) — Contrôle du trafic IA

Azure API Management, avec sa couche **AI Gateway**, offrirait un point de contrôle centralisé pour tout le trafic entre les agents et les modèles IA :

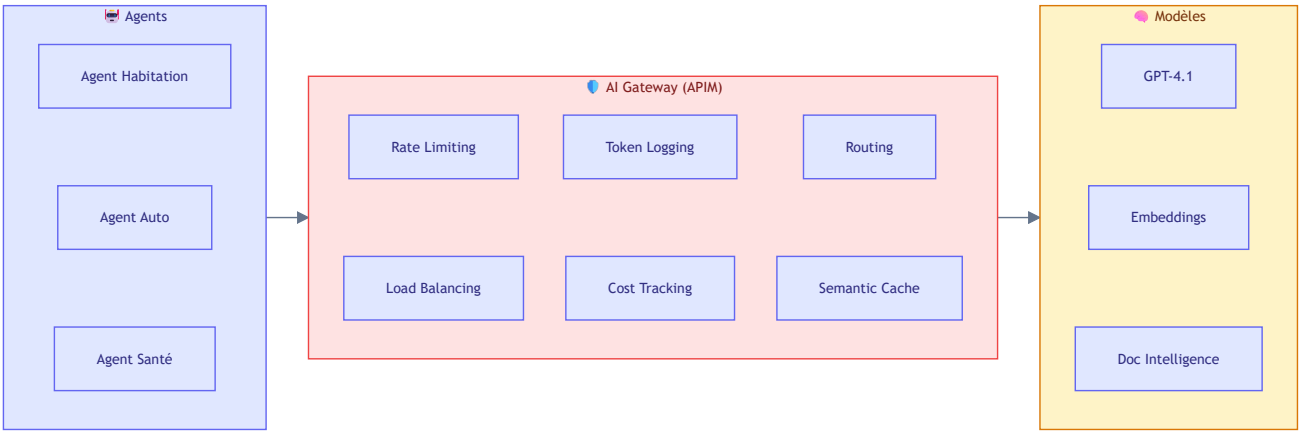

Capacité AI Gateway	Description
Rate limiting	Quotas par agent, par utilisateur ou par workflow — évite les abus et maîtrise les coûts
Load balancing	Répartition du trafic entre plusieurs déploiements de modèles (failover, latence)
Token logging	Comptage des tokens consommés par agent pour le chargeback et le reporting
Cost tracking	Suivi du coût par requête, par agent, par persona — dashboards Azure Monitor
Semantic caching	Cache des réponses similaires pour réduire les appels redondants et la latence
Content filtering	Filtrage des entrées/sorties via Azure Content Safety (texte, images)
Circuit breaker	Protection contre les cascades d'erreurs — fallback automatique
Routing intelligent	Acheminement vers le modèle optimal selon la complexité (nano → mini → full)

Azure Content Safety — Guardrails IA

Protection	Périmètre
Prompt injection	Détection et blocage des tentatives de contournement des instructions agent
Groundedness	Vérification que les réponses sont ancrées dans les données fournies (pas d'hallucination)
Protected material	Détection de contenu protégé par le droit d'auteur
PII detection	Identification et masquage des données personnelles (RGPD)
Custom categories	Catégories personnalisées pour le domaine assurance (ex. : termes médicaux sensibles)

Matrice de gouvernance par couche

Couche	Service	Rôle dans la gouvernance
Identité	Entra ID	Identité managée par agent, OBO, RBAC, audit
Registre	Entra Agent Registry	Publication, découverte, consentement, distribution M365
Gateway	APIM + AI Gateway	Rate limiting, load balancing, cost tracking, caching
Sécurité contenu	Content Safety	Prompt injection, PII, groundedness, filtrage
Runtime	Foundry Agent Service	Hébergement managé, auto-scaling, tracing OpenTelemetry
Runtime (alt.)	Azure Container Apps	Hébergement custom, KEDA scaling, VNet isolation
Données	Purview + Fabric	Classification, lineage, conformité RGPD
Observabilité	App Insights + Monitor	Traces, métriques, alertes, dashboards
Évaluation	Foundry Evaluation	Qualité agents, datasets, amélioration continue

---

13. Stockage des résultats agents — Traçabilité et entraînement

Les agents produiraient des **résultats transformés** à stocker pour la traçabilité réglementaire, l'amélioration continue des prompts, et l'entraînement des modèles.

Architecture de stockage des outputs agents

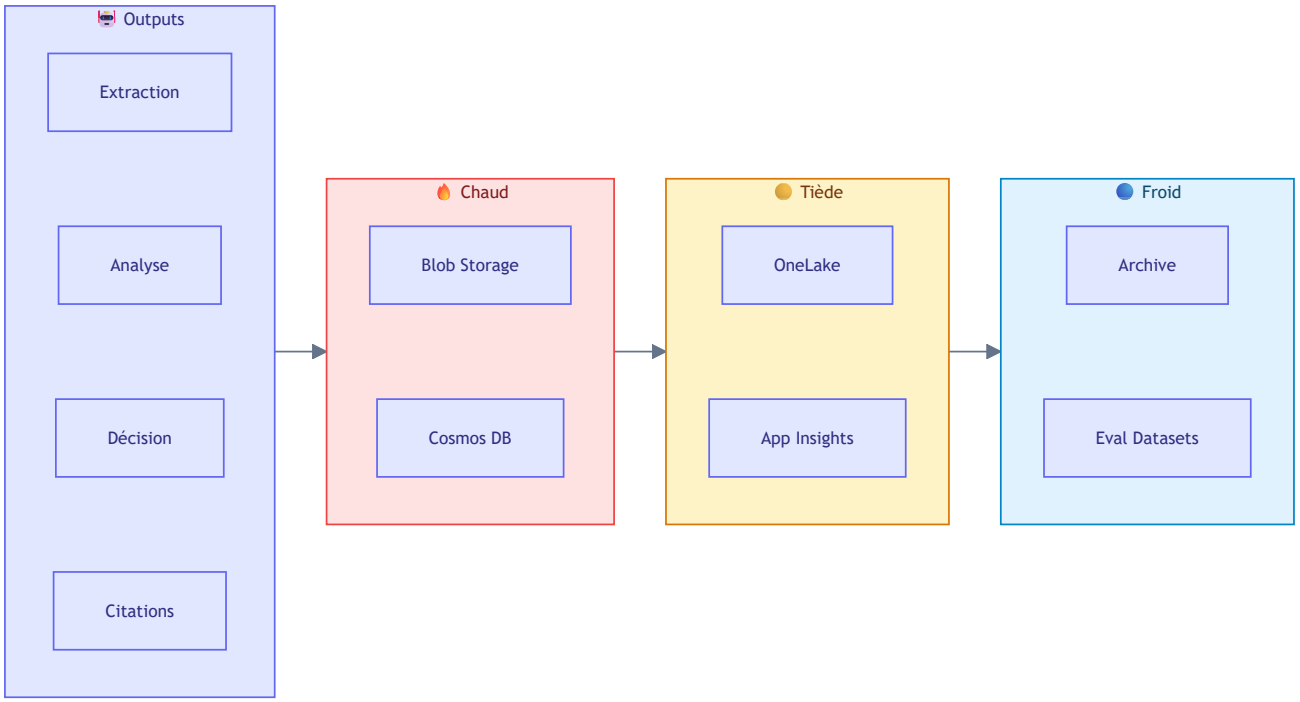

Ce qui est stocké par type

Type de donnée	Stockage	Rétention	Usage
Extraction CU (champs structurés)	Blob Storage (JSON)	Durée du dossier	Dashboard, audit
Analyse GPT-4.1 (résumé, scoring)	Blob Storage (JSON)	Durée du dossier	Décision, rapport PDF
Décision agent (couverture, montant)	Blob Storage + Cosmos DB	Réglementaire (5+ ans)	Traçabilité, conformité
Citations RAG (articles, pages)	Blob Storage (JSON)	Durée du dossier	Justification, audit
Traces agents (steps, tool calls)	Application Insights	90 jours	Debugging, monitoring
Métriques performance (latence, coût)	Application Insights	90 jours	Optimisation, SLA
Historique conversations	Cosmos DB	Session + archive	Continuité, contexte
Datasets d'évaluation	OneLake (Fabric)	Long terme	Évaluation qualité agents
Données d'entraînement	OneLake Archive	Long terme	Fine-tuning, prompt optim

Pipeline d'amélioration continue des agents

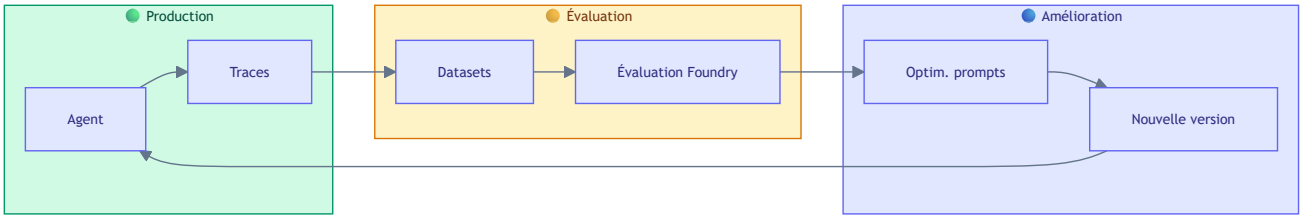

Évaluateurs Foundry disponibles

Évaluateur	Ce qu'il mesure
Intent Resolution	L'agent comprend-il correctement la demande ?
Task Adherence	L'agent suit-il ses instructions et contraintes ?
Tool Call Accuracy	L'agent appelle-t-il les bons outils avec les bons paramètres ?
Relevance	Les réponses sont-elles pertinentes par rapport au contexte ?
Coherence	Les réponses sont-elles cohérentes dans un dialogue multi-tour ?

---

14. Amélioration continue par le retour humain (Human-in-the-Loop)

Les agents de conseil ne seraient pas figés : ils s'amélioreraient **en permanence** grâce aux interventions des gestionnaires. Chaque correction, classification modifiée ou décision ajustée par un humain enrichirait la base de connaissance et affinerait les instructions des agents.

Boucle de rétroaction humaine

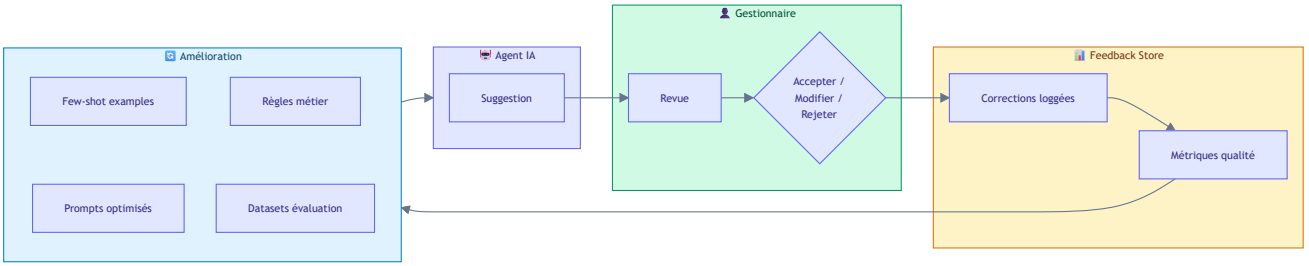

Types d'interventions humaines et leur impact

Intervention humaine	Exemple assurance	Impact sur l'agent
Correction de classification	Le gestionnaire reclasse un sinistre de « dégâts des eaux » en « tempête »	L'agent apprend à mieux distinguer les catégories via few-shot examples mis à jour
Modification du scoring	Ajustement d'un score de risque de 7/10 à 4/10 avec justification	Les seuils de scoring sont recalibrés dans les instructions de l'agent
Ajout d'exclusion	Le gestionnaire identifie une clause d'exclusion manquée par l'agent	La clause est ajoutée aux règles RAG de recherche de polices
Rejet d'hallucination	L'agent cite un article de police inexistant, le gestionnaire signale l'erreur	Le feedback alimente un dataset d'évaluation de « groundedness »
Ajustement de montant	Modification du montant de remboursement proposé (de 12 500 € à 8 200 €)	Les barèmes et plafonds dans les prompts sont affinés
Validation de fraude	Confirmation ou infirmation d'un indicateur de fraude détecté	Le modèle de détection de fraude est renforcé (précision / rappel)
Enrichissement contextuel	Ajout d'informations manquantes (antécédents, photos supplémentaires)	L'agent apprend les champs critiques à demander en priorité

Pipeline d'amélioration par le feedback humain

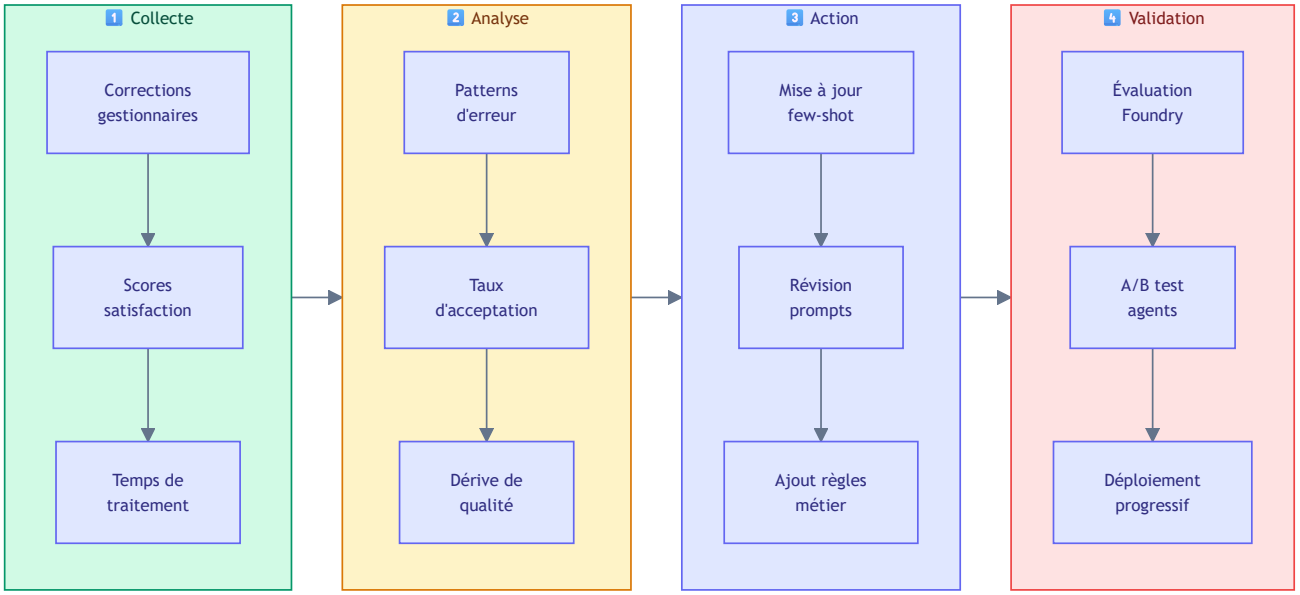

Métriques de suivi Human-in-the-Loop

Métrique	Description	Cible
Taux d'acceptation	% de suggestions agent acceptées sans modification	> 80 % à terme
Taux de correction	% de suggestions modifiées avant validation	< 15 % (en baisse)
Taux de rejet	% de suggestions rejetées par le gestionnaire	< 5 %
Temps moyen de revue	Durée entre suggestion et validation/rejet	En baisse continue
Score de confiance calibré	Corrélation entre le score de confiance agent et le taux d'acceptation réel	> 0.85
Dérive de qualité	Évolution du taux d'acceptation dans le temps (détection de régression)	Stable ou en hausse

Exemple concret — Sinistres Habitation

1. **L'agent analyse** un dégât des eaux et propose : couverture confirmée, montant estimé 15 000 €, score 8/10
2. **Le gestionnaire revoit** : reclasse en « dommages post-événement climatique », ajuste à 11 000 € (plafond contractuel), score 6/10
3. **Le feedback est capturé** : la correction est loggée avec la justification (plafond art. 12.3, exclusion vétusté)
4. **Le système apprend** :
   - Le cas est ajouté comme **few-shot example** pour la catégorisation post-événement climatique
   - Le prompt de l'agent est enrichi avec la **référence au plafond art. 12.3**
   - Un nouveau cas de test est ajouté au **dataset d'évaluation Foundry**
5. **L'évaluation confirme** : sur les 50 prochains cas similaires, le taux d'acceptation passe de 62 % à 84 %

> **Vision** : à mesure que les gestionnaires corrigent et valident les suggestions agents, ceux-ci deviendraient progressivement plus précis, plus fiables et plus alignés avec les pratiques métier réelles. L'humain resterait toujours décisionnaire final, mais passerait de « corriger systématiquement » à « superviser et valider ».

---

15. Stratégie d'adoption progressive — Liberté de choix

> **Principe clé** : le client adopte à son rythme, module par module. Chaque brique apporte de la valeur indépendamment des autres. Aucun engagement « tout ou rien ».

Phases d'adoption suggérées

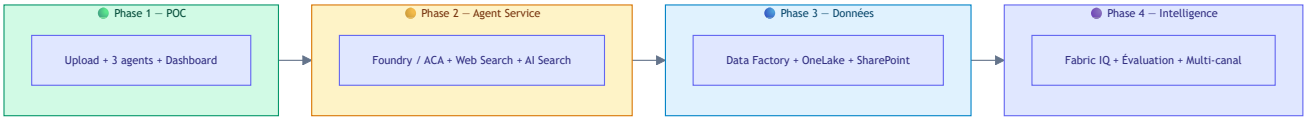

Détail par phase

Phase	Durée estimée	Prérequis	Valeur ajoutée	Indépendance
Phase 1 — POC ✅	Livré	Aucun	Validation pipeline agentique, ROI sur 5 personas	—
Phase 2 — Agent Service	4-6 semaines	Foundry project	Runtime managé, Web Search, observabilité bout en bout	✅ Peut être fait sans Phase 3
Phase 3 — Données entreprise	8-12 semaines	Fabric capacity, Data Gateway	Données ERP/legacy dans les agents, fini le re-keying	✅ Peut être fait sans Phase 2
Phase 4 — Intelligence	Continu	Phases 2 + 3	Ontologie métier, évaluation, distribution Teams/Copilot	Nécessite les phases précédentes

Ce que le client peut prendre séparément

Brique	Standalone ?	Description
Web Search	✅ Oui	Ajout simple : un outil built-in dans l'agent existant
AI Search (polices)	✅ Oui	Remplace pgvector — migration d'index, même API
Foundry Agent Service	✅ Oui	Migration du runtime Python custom → managé
SharePoint	✅ Oui	Outil built-in Foundry, accès documents existants
Data Factory (ERP/SQL)	✅ Oui	Ingestion batch, indépendant des agents
OneLake	✅ Oui	Stockage unifié, fonctionne sans Fabric IQ
Fabric IQ	⚠️ Avec Fabric	Nécessite OneLake et Fabric capacity
MCP Servers (SI)	⚠️ Développement	Nécessite développement custom par API on-premise
Teams / Copilot	⚠️ Avec Agent Service	Publication via Entra Agent Registry

Glossaire

Terme	Définition
FabricIQ	Plateforme de données Microsoft Fabric, incluant Data Factory (ingestion), OneLake (stockage unifié), et Fabric IQ (ontologie + data agents)
FoundryIQ	Plateforme d'agents IA Microsoft Foundry, incluant Agent Service (orchestration), Foundry IQ (knowledge retrieval) et le catalogue de modèles
OneLake	Lac de données unifié dans Fabric — toutes les données organisationnelles dans un seul endroit, format Delta Lake ouvert
Data Gateway	Passerelle logicielle installée dans le réseau du client pour connecter les systèmes on-premise au cloud de façon sécurisée
Fabric IQ	Workload Fabric (preview) : ontologie métier, data agents, semantic models, graphe de données
Foundry IQ	Système de knowledge retrieval de Foundry — RAG clé en main pour grounding des agents
MCP Server	Model Context Protocol — standard ouvert permettant aux agents Foundry d'appeler des APIs externes (on-premise, SaaS)
APIM	Azure API Management — passerelle d'APIs qui expose les services internes vers le cloud avec sécurité et monitoring
OBO (On-Behalf-Of)	Mécanisme d'authentification où l'agent agit avec l'identité de l'utilisateur final (pas un compte technique)
SAP CDC	SAP Change Data Capture — extraction incrémentale des modifications (deltas) depuis SAP via le framework ODP
Agent Service	Runtime managé de Foundry qui héberge, scale et sécurise les agents IA sans infrastructure à gérer
RAG	Retrieval-Augmented Generation — enrichir les réponses IA avec des documents réels (polices Groupama, historique sinistres)
Workflow Agent	Agent Foundry qui orchestre plusieurs agents en séquence avec branchements, approbations, et logique métier
GDS / TDS / LTV	Ratios financiers réglementaires pour l'éligibilité hypothécaire (Gross/Total Debt Service, Loan-to-Value)
Purview	Service de gouvernance Microsoft intégré à Fabric : classification, contrôle d'accès, audit, conformité RGPD
Microsoft Agent Framework	SDK Python/.NET pour construire des Hosted Agents avec logique custom, outils @ai_function, et déploiement container sur Foundry Agent Service
Web Search (GA)	Outil built-in Foundry qui utilise Grounding with Bing Search pour enrichir les réponses agents avec des données web en temps réel et des citations inline

Terme	Définition
Hosted Agent	Agent basé sur du code custom (Python, .NET), packagé en container Docker et déployé sur Foundry Agent Service ou Azure Container Apps avec auto-scaling
A2A (Agent-to-Agent)	Protocole de communication entre agents Foundry via endpoints A2A-compatibles (preview)
Prompt Optimization	Processus itératif d'amélioration des instructions agents via évaluation automatisée (datasets + métriques Foundry)
Evaluation Datasets	Paires question/réponse attendue utilisées pour mesurer objectivement la qualité des agents sur les métriques Intent Resolution, Task Adherence, Tool Call Accuracy
Entra Agent Registry	Registre centralisé dans Microsoft Entra ID pour publier, découvrir et distribuer les agents vers M365 Copilot, Teams et applications custom
Agents 365	Agents enregistrés dans l'Entra Agent Registry et invocables depuis Microsoft 365 Copilot, Teams, Outlook
AI Gateway (APIM)	Couche d'Azure API Management dédiée au trafic IA : rate limiting, load balancing, token logging, cost tracking, semantic caching
Content Safety	Service Azure de filtrage et protection IA : détection prompt injection, PII, groundedness, contenu protégé
Control Plane	Ensemble des services de gouvernance (Entra ID, Agent Registry, AI Gateway, Content Safety) qui encadrent le cycle de vie des agents
Stratégie hybride	Approche architecturale combinant plusieurs frameworks (Agent Framework SDK, LangChain/LangGraph, Prompt Agents) selon les besoins de chaque workload
Human-in-the-Loop (HITL)	Boucle de rétroaction où les corrections et validations humaines alimentent l'amélioration continue des agents (few-shot, prompts, règles)
Few-shot examples	Exemples concrets (entrée → sortie attendue) ajoutés aux prompts agents pour guider le comportement sur des cas spécifiques, enrichis au fil des corrections humaines
Taux d'acceptation	Métrique clé HITL : pourcentage de suggestions agent acceptées sans modification par les gestionnaires — indicateur de maturité de l'agent
OneLake Shortcuts	Références virtuelles (zero-copy) dans OneLake pointant vers des données externes (ADLS, S3, GCS, SharePoint) sans copie ni déplacement
Data Residency	Principe selon lequel les données restent dans leur localisation géographique et leur stockage d'origine, sans transfert vers un lac centralisé

FAQ — Questions fréquentes sur les données et l'architecture

Localisation et souveraineté des données

Q : Mes données doivent-elles être déplacées dans OneLake ou Fabric pour que la plateforme agentique fonctionne ?

Non. La plateforme agentique (Foundry + agents) peut fonctionner **sans Microsoft Fabric**. Les agents Foundry accèdent directement aux données via :

- **Azure AI Search** (index sémantique sur vos documents, où qu'ils soient stockés)
- **Azure Blob Storage** (documents, PDFs, photos)
- **SharePoint** (outil built-in Foundry avec authentification OBO)
- **MCP Servers** (pont vers vos APIs on-premise : GED, tarificateur, etc.)
- **APIs REST** via APIM (tout système exposé en HTTP)

Les données restent là où elles sont. Aucune migration n'est requise.

Q : Foundry IQ peut-il fonctionner sans Fabric ?

Oui. Foundry IQ est une **couche de connaissance autonome** (knowledge layer) indépendante de Fabric. Ses sources de connaissances supportées incluent :

- Azure Blob Storage
- SharePoint
- OneLake (si Fabric est présent)
- Données web publiques

Foundry IQ est bâti sur **Azure AI Search** (agentic retrieval) — pas sur Fabric. *(Source : Foundry IQ FAQ — Microsoft Learn)*

Q : Quelle est la différence entre Fabric IQ, Foundry IQ et Work IQ ?

Ce sont **trois couches IQ indépendantes**, chacune autonome :

IQ	Périmètre	Prérequis	Standalone ?
Foundry IQ	Connaissances entreprise (documents, Blob, SharePoint, web)	Azure AI Search	✅ Oui
Fabric IQ	Données analytiques (ontologie, semantic models, data agents)	Microsoft Fabric	✅ Oui
Work IQ	Collaboration M365 (documents, réunions, chats)	Microsoft 365	✅ Oui

On peut utiliser un, deux ou trois IQ ensemble. La plateforme agentique ne nécessite que **Foundry IQ** au minimum. *(Source : Foundry IQ — Relationship to Fabric IQ and Work IQ)*

Q : Si j'utilise Fabric, mes données sont-elles copiées ?

Pas forcément. Fabric offre deux stratégies complémentaires :

Stratégie	Copie ?	Mécanisme	Cas d'usage
Shortcuts (recommandé)	❌ Non	Référence virtuelle vers ADLS, S3, GCS, SharePoint	La donnée reste chez le client, zero-copy
Mirroring	✅ Oui (réplication)	CDC continu depuis bases opérationnelles	Bases transactionnelles SQL, Cosmos DB
Pipelines (Data Factory)	✅ Oui (batch)	ETL classique avec transformation	Historique ERP, référentiels

Avec les **Shortcuts**, les moteurs Fabric interrogent les données **in place** sans aucune copie. *(Source : Get data into Fabric — Shortcuts)*

Architecture sans Fabric

Q : Peut-on faire fonctionner la plateforme agentique complète sans Fabric ?

Oui. Voici l'architecture minimale sans Fabric :

Composant	Sans Fabric	Avec Fabric
Stockage documents	Azure Blob Storage	OneLake (ou Shortcuts vers Blob)
RAG / Polices	Azure AI Search + Foundry IQ	Azure AI Search + Foundry IQ + Fabric IQ
Données ERP/legacy	MCP Servers + APIs REST via APIM	Data Factory → OneLake + Fabric Data Agent
Agent runtime	Foundry Agent Service / ACA	Foundry Agent Service / ACA
Modèles IA	Azure OpenAI / Foundry Models	Azure OpenAI / Foundry Models
Gouvernance	Entra ID + APIM + Purview	Entra ID + APIM + Purview + Fabric Gov
Ontologie métier	❌ Non disponible	✅ Fabric IQ (semantic models, data agents)
Langage naturel sur données	❌ Non disponible	✅ Fabric Data Agent

> Fabric apporte un **plus** (ontologie, Data Agents, unification), mais n'est pas requis pour le pipeline agentique.

Q : Quand Fabric devient-il vraiment utile ?

Fabric ajouterait une valeur significative dans ces scénarios :

Scénario	Pourquoi Fabric ?
Client 360 (agrégation cross-domaine)	OneLake unifie les données de multiples sources ; Fabric Data Agent permet des requêtes en langage naturel
Reporting Power BI avancé	Semantic models Fabric alimentent Power BI avec gouvernance intégrée
Historique massif (millions de sinistres)	OneLake + Spark traitent les volumes que Blob + AI Search seuls ne gèrent pas efficacement
Ontologie métier partagée	Fabric IQ standardise les définitions (sinistre, prime, assuré) entre tous les agents
ERP intégration profonde	Data Factory offre 200+ connecteurs batch natifs (SAP, Oracle, etc.)

Sécurité et conformité

Q : Les données traitées par les agents restent-elles dans Azure ?

Oui. Azure AI Agent Service garantit que :

- Les données (prompts, réponses) ne sont **PAS** partagées avec d'autres clients
- Les données ne sont **PAS** utilisées pour entraîner les modèles OpenAI, Meta ou Mistral
- Le traitement se fait dans la **région Azure choisie** (ex. France Central)

Exception : l'outil Grounding with Bing Search transfère des données hors du boundary Azure (soumis à des conditions d'utilisation séparées). Ce tool est désactivable par l'administrateur. *(Source : Data, privacy, and security for Agent Service)*

Q : Puis-je contrôler la région de déploiement de mes agents ?

Oui. Tous les composants (Foundry, AI Search, Blob, OpenAI) sont déployés dans une région Azure spécifique (ex. **France Central**). Les données ne quittent pas cette région sauf activation explicite de services cross-région (Bing Search, geo-replication).

Coût et progressivité

Q : Quel est le coût d'entrée minimum pour la plateforme agentique ?

Niveau	Composants	Coût indicatif
Minimum (POC actuel)	Azure OpenAI + Blob + App Service	~200 €/mois
Production sans Fabric	Foundry Agent Service + AI Search + Blob + APIM	~500–1 500 €/mois
Production avec Fabric	Ci-dessus + Fabric F2/F4 capacity	+1 000–3 000 €/mois

> Fabric représente le coût le plus élevé. Démarrer sans Fabric et l'ajouter ultérieurement est parfaitement viable et recommandé.

Q : Puis-je commencer sans Fabric et l'ajouter plus tard ?

Oui, c'est l'approche recommandée. La stratégie d'adoption (section 15) prévoit :

1. **Phase 1** : POC avec Blob + AI Search (livré)
2. **Phase 2** : Foundry Agent Service (sans Fabric)
3. **Phase 3** : Fabric (si nécessaire pour Client 360, ERP, ontologie)

Chaque phase est indépendante. Aucun engagement « tout ou rien ».