GroupaIQ

Architecture Agentique — POC — Avril 2026

> Ce document présente l'**architecture agentique du POC GroupaIQ** actuellement déployé en production. Trois agents IA spécialisés orchestrent l'analyse des documents d'assurance via une pipeline **Document Intelligence → GPT-4.1 → RAG**.
>
> Pour l'architecture cible avec Fabric IQ, Foundry IQ, Microsoft Agent Framework, et sources de données hétérogènes, voir ARCHITECTURE-AGENTIC-V2-TARGET.md.

1. Vue d'ensemble — Pipeline agentique

Le POC GroupaIQ repose sur **trois agents spécialisés** qui travaillent en séquence pour transformer un document brut (PDF, photo, scan) en une décision métier documentée.

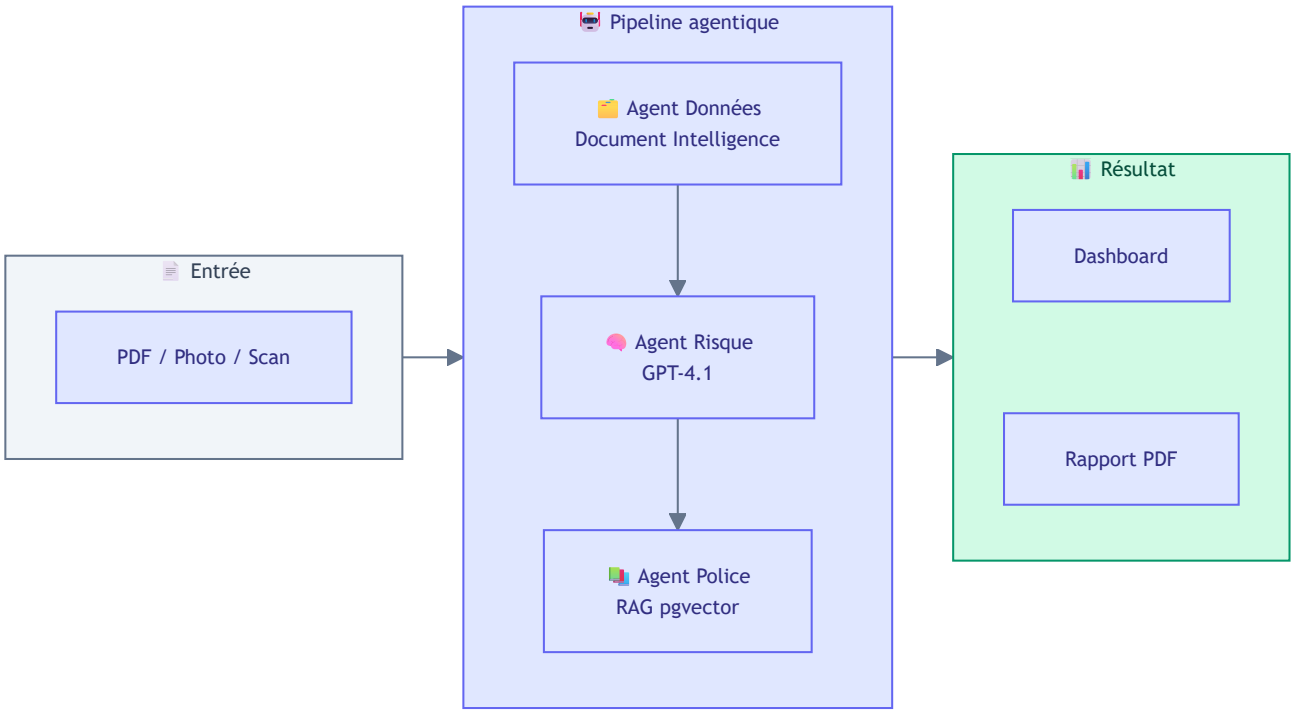

Agent	Rôle	Technology Azure
Agent Données	Extrait les champs structurés du document (dates, montants, noms, adresses)	Azure Document Intelligence (Content Understanding)
Agent Risque	Analyse le contenu, évalue les risques, détecte les anomalies, scoring	Azure OpenAI GPT-4.1 (+ multimodal pour les photos)
Agent Police	Recherche les articles applicables dans les Conditions Générales Groupama	PostgreSQL 16 + pgvector (recherche sémantique RAG)

2. Les 5 personas métier

GroupaIQ sert **cinq workflows métier distincts**, chacun activant les trois agents avec des prompts et des polices de référence adaptés.

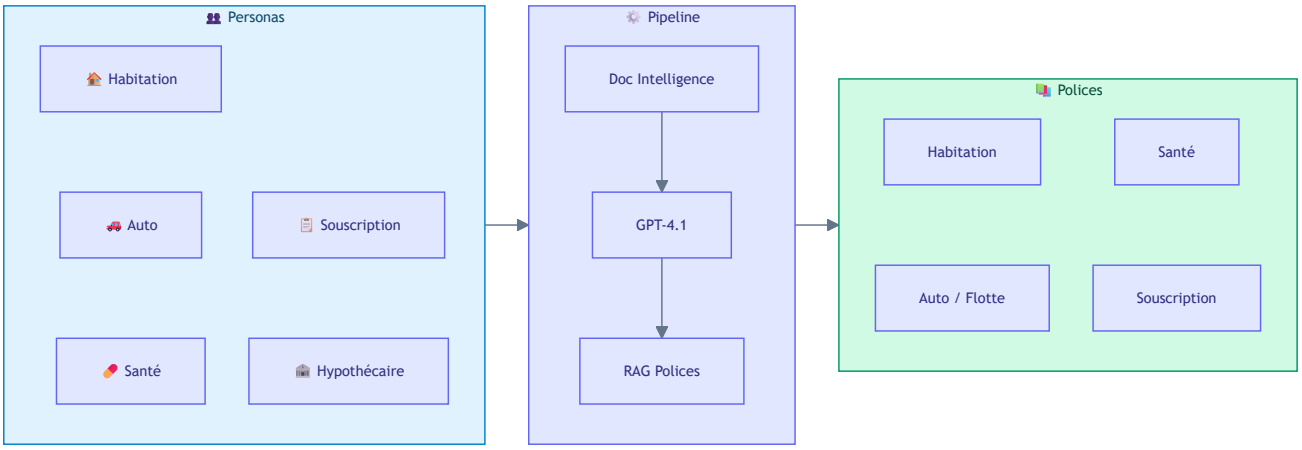

Persona	Document type	Polices RAG	Résultat clé
Sinistres Habitation	Déclaration sinistre MRH	Conditions Générales Habitation	Estimation dommages, couverture, exclusions
Sinistres Auto	Constat amiable + photos	Conditions Auto / Flotte Auto	Évaluation dégâts, responsabilité, fraude
Sinistres Santé	Facture hospitalière, devis optique	Complémentaire Santé	Remboursement, plafonds, exclusions
Souscription	APS médical, questionnaire santé	Souscription Santé	Scoring risque, recommandation
Hypothécaire	Dossier emprunteur, évaluation bien	—	Ratios GDS/TDS/LTV, éligibilité

3. Architecture technique déployée

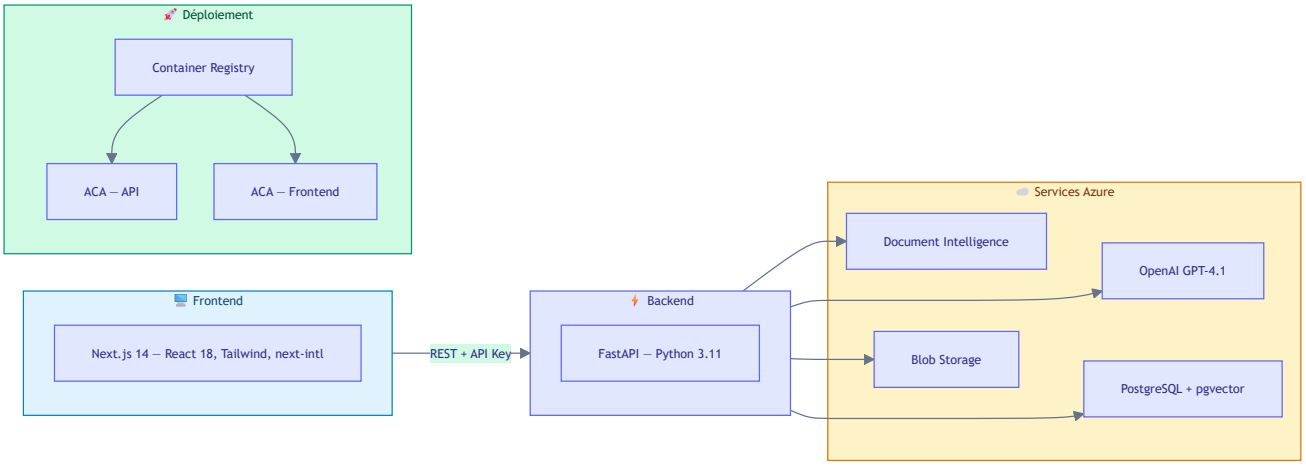

Composant	Technologie	Région Azure
Frontend	Next.js 14, TypeScript, Tailwind, next-intl (fr)	France Central
Backend	Python 3.11, FastAPI, Gunicorn + Uvicorn	France Central
Extraction	Azure Document Intelligence (Content Understanding)	France Central
LLM	Azure OpenAI GPT-4.1 (2025-04-14)	France Central
Embeddings	text-embedding-3-large (3072 dims)	France Central
Stockage	Azure Blob Storage	France Central
RAG	PostgreSQL 16 Flexible Server + pgvector	France Central
Registre images	Azure Container Registry	France Central
Hébergement	Azure Container Apps (2 apps)	France Central

4. Séquence — Traitement d'un sinistre habitation

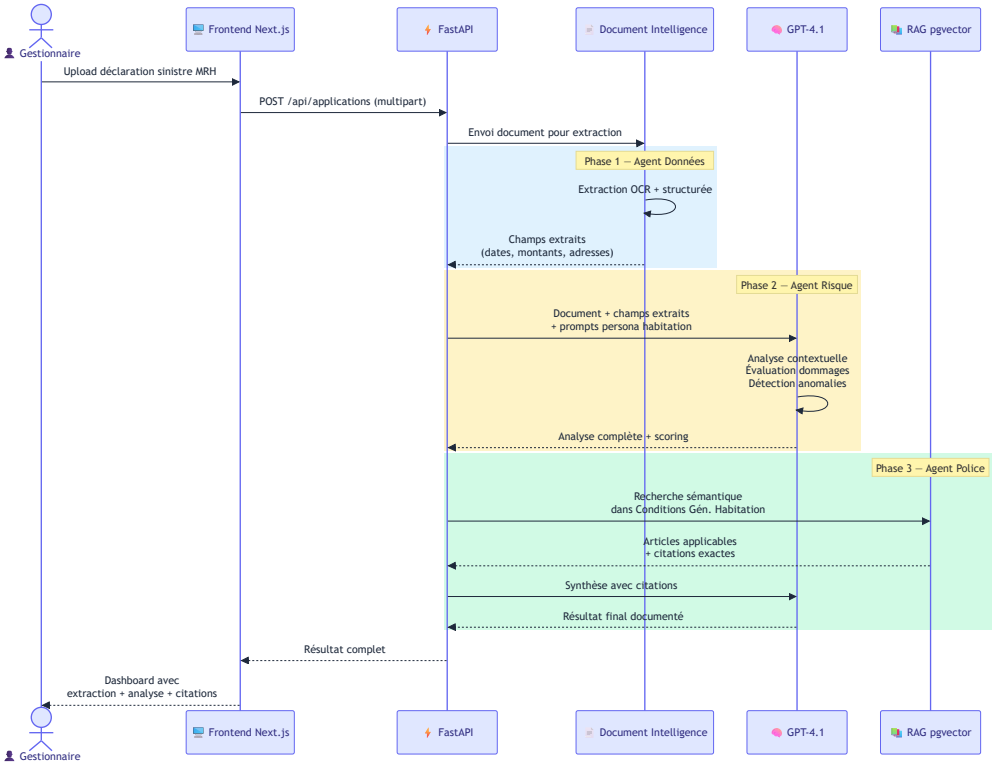

5. Pipeline IA en 3 couches — Flux détaillé

L'analyse GroupalQ repose sur un pipeline séquentiel à **3 couches** : extraction documentaire, injection de templates avec contexte métier, puis analyse LLM avec sortie JSON stricte.

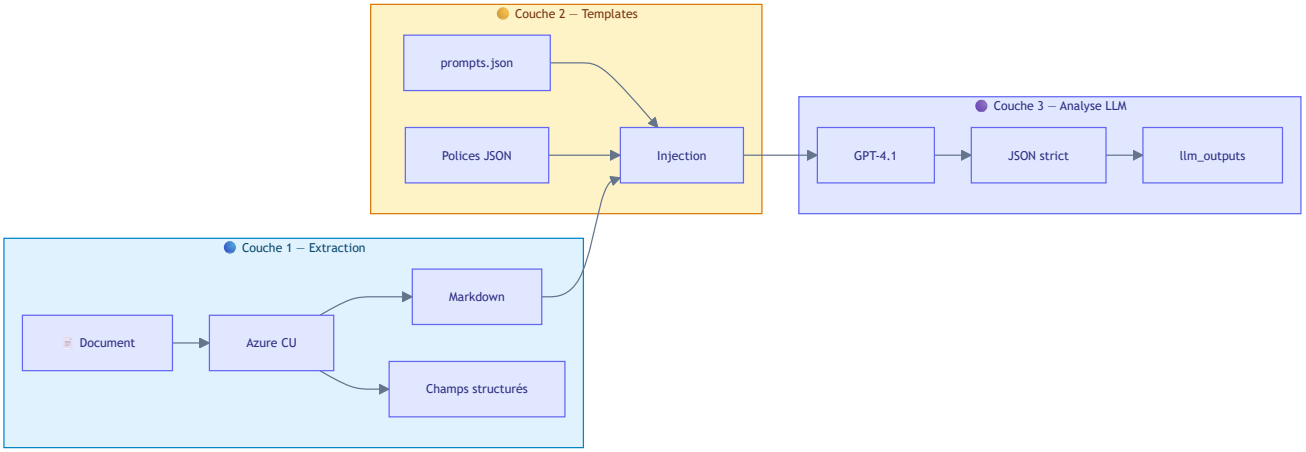

Couche 1 — Extraction (Azure Content Understanding)

Chaque fichier est routé automatiquement vers l'analyseur approprié selon son type et le persona actif.

Type de fichier	Analyseur	Données extraites
PDF / Documents	`prebuilt-documentSearch` (défaut) ou analyseur custom	Markdown sémantique + champs structurés
Images (.jpg/.png)	`prebuilt-image` ou `autoClaimsImageAnalyzer` (auto)	Zones de dommages, sévérité, score de confiance
Vidéos (.mp4/.mov)	`autoClaimsVideoAnalyzer` (auto)	Keyframes, segments temporels, transcription

Persona	Analyseur Documents	Analyseur Images	Analyseur Vidéo
Souscription	prebuilt-documentSearch	prebuilt-image	—
Sinistres Santé	prebuilt-documentSearch	prebuilt-image	—
Sinistres Auto	autoClaimsDocAnalyzer	autoClaimsImageAnalyzer	autoClaimsVideoAnalyzer
Sinistres Habitation	prebuilt-documentSearch	prebuilt-image	—
Hypothécaire	prebuilt-documentSearch	prebuilt-image	—

Couche 2 — Templates et Contexte Métier

Les prompts sont organisés en **sections / subsections** dans `prompts.json`, avec injection de variables à l'exécution :

Variable injectée	Source	Rôle
`{underwriting_policies}`	Fichiers `*-policies.json` par persona	Règles métier et barèmes applicables
Document markdown	Extraction CU (couche 1)	Contenu brut du document analysé
`additional_context`	Résumés par lots (documents > 100 Ko)	Contexte étendu pour gros documents
`{glossary}`	`prompts/glossary.json`	Terminologie métier standardisée

Couche 3 — Analyse LLM (GPT-4.1)

- Sections exécutées **séquentiellement** (dépendances entre sections)
- Subsections exécutées **en parallèle** (4 workers)
- Sortie JSON **stricte** avec réparation automatique si troncature
- Résultat stocké dans `llm_outputs[section][subsection]`

---

6. Logique de raisonnement — Agent Risque

L'Agent Risque (GPT-4.1) applique une **chaîne de raisonnement structurée** pour chaque dossier. Le raisonnement varie selon le persona mais suit toujours le même pattern.

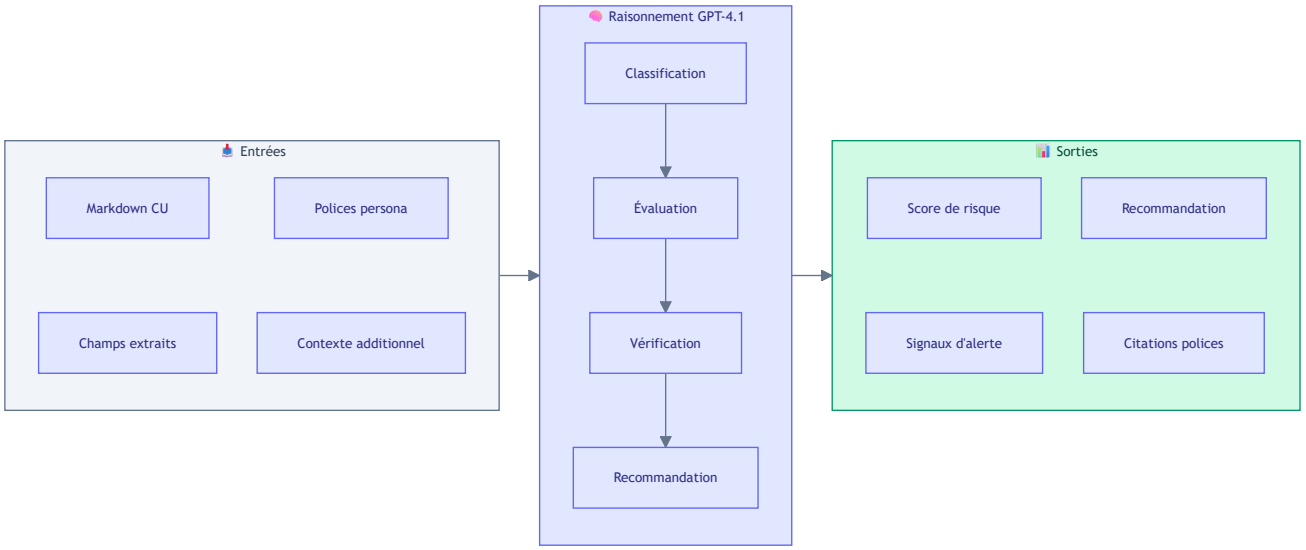

Étapes de raisonnement par persona

Étape	Sinistres Auto	Sinistres Habitation	Souscription Santé
1. Classification	Type de dommage (mineur → perte totale), zones touchées	Nature du sinistre (DDE, incendie, vol), étendue	Profil médical, classe de risque
2. Évaluation	Estimation coût (pièces + MO + peinture), responsabilité %	Montant estimé, contenu vs structure	Scoring pathologies, antécédents familiaux
3. Vérification	Articles CG Auto applicables, exclusions, franchise	Articles CG Habitation, IRSI, Cat-Nat, franchise DDE	Polices souscription, exclusions médicales
4. Recommandation	Montant ± 20%, subrogation si tiers >50%	Indemnisation, mandat expert si >5 000 €	Acceptation / surprime / refus + justification

Classification des dommages (Sinistres Auto)

Niveau	Dommage	Coût estimé	Action déclenchée
🟢 **Mineur**	Rayure / bosse < 15 cm	0 – 1 000 €	Approbation rapide
🟡 **Modéré**	Dommages multi-panneaux	1 000 – 5 000 €	Documentation photo requise
🟠 **Lourd**	Airbag / structure / suspension	5 000 – 15 000 €	Revue senior + inspection
🔴 **Perte totale**	Réparation > 70 % valeur véhicule	Variable	Évaluation de récupération

Détection de fraude — Signaux d'alerte

L'Agent Risque produit un **score de fraude** avec indicateurs classés par sévérité :

Niveau	Signal	Exemple
🔴 **Élevé**	Incohérence majeure	Description "accident stationnement" mais dommages compatibles avec collision haute vitesse
🟡 **Modéré**	Élément à vérifier	Sinistre déclaré 3 jours après les faits, pas de témoin
🟢 **Faible**	Aucune anomalie	Dossier cohérent, preuves concordantes

---

7. Chaîne de valeur — Impact métier des agents

Les 4 agents et leur impact

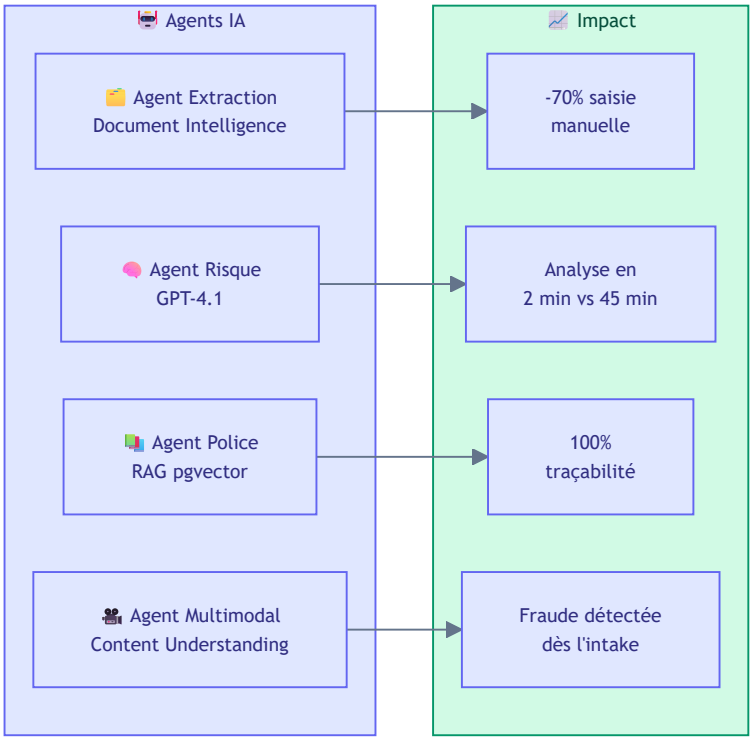

Score d'impact business

Métrique	Avant GroupaIQ	Après GroupaIQ	Gain
Temps FNOL	30-45 min	3-5 min	**-85 %**
Saisie manuelle	100 %	30 %	**-70 %**
Détection fraude	Manuelle, tardive	Automatique, dès l'intake	**+80 % détection**
Conformité polices	Vérification humaine	Citations automatiques	**100 % traçabilité**
Satisfaction client (NPS)	Délais élevés	Réponse rapide	**+25 points**
Ratio de dépenses	Élevé	Réduit	**-30 %**

Détail par agent

Agent	Périmètre	Impact principal
🗂️ **Agent Extraction**	Constats, factures, rapports médicaux, CG → markdown sémantique indexé	Suppression de 70 % de la saisie manuelle
🧠 **Agent Risque**	Analyse multimodale (texte + image + vidéo), scoring, responsabilité, fraude	Analyse en 2 min vs 30-45 min, cohérence des décisions
📚 **Agent Police**	4 PDF CG Groupama vectorisés, recherche sémantique en français	Conformité garantie, décisions traçables et auditables
🎥 **Agent Multimodal**	Photos → zones de dommages + sévérité, vidéos → keyframes + timeline	Évaluation visuelle automatique, croisement déclaration vs preuves

---

8. RAG — Recherche dans les polices Groupama

4 documents indexés

Fichier PDF	Catégorie	Catégorie DB
Conditions Générales Habitation	Habitation	property_casualty
Complémentaire Santé	Santé	life_health
Conditions Générales Auto	Auto	automotive
Conditions Générales Flotte Auto	Flotte	automotive

Méthodes de recherche

Méthode	Description
semantic_search()	Similarité vectorielle pure (cosine)
filtered_search()	Vecteur + filtres métadonnées (catégorie, risk_level)
intelligent_search()	LLM infère la catégorie → vecteur + filtre
hybrid_search()	pgvector + trigram text search combinés

Pipeline d'indexation

---

9. Customer 360 — Vue client unifiée

Le persona **Client 360** agrège les données de tous les workflows en une vue unifiée par client.

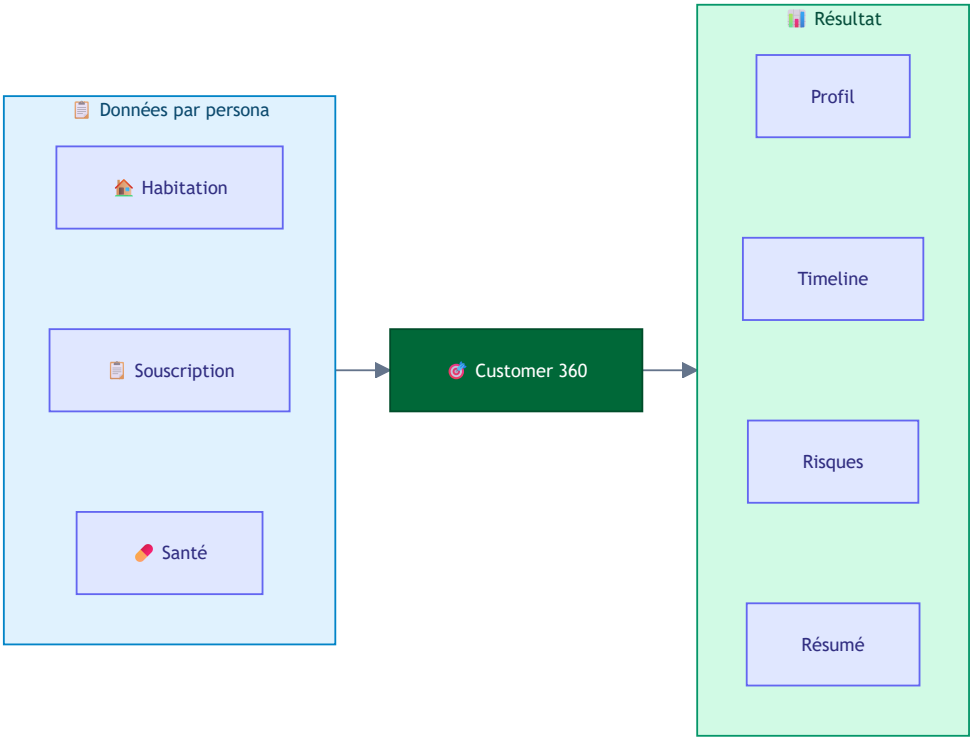

- **30 clients Groupama** pré-importés (GRP-001 à GRP-030)
- **GRP-001** (Olivier MERTENS LAFFITE) : lié aux démos habitation + souscription
- **GRP-016** (Aurélie FONTAINE) : liée à la démo santé
- **Persistance** : Azure Blob Storage (survit aux redéploiements)

---

10. Sécurité et gouvernance

Aspect	Implémentation POC
Authentification API	API Key (min 32 caractères)
Stockage	Azure Blob Storage (résidence France Central)
Réseau	Container Apps avec HTTPS
Données sensibles	Pas de données réelles en POC
CI/CD	GitHub Actions + OIDC (pas de secret client)
Observabilité	Logs applicatifs + health check `/`

---

11. Métriques POC

Métrique	Valeur POC
Temps extraction CU	15-45 secondes par document
Temps analyse GPT-4.1	10-30 secondes
Temps recherche RAG	< 1 seconde
5 personas opérationnelles	Habitation, Auto, Santé, Souscription, Hypothécaire
4 polices indexées	~200 chunks vectorisés
30 clients démo	Données Customer 360 persistées

Glossaire

Terme	Définition
Content Understanding	Service Azure Document Intelligence qui extrait des champs structurés de documents non structurés (PDF, photos, scans)
GPT-4.1	Modèle de langage Azure OpenAI utilisé pour l'analyse contextuelle, le scoring de risque et la synthèse
pgvector	Extension PostgreSQL pour le stockage et la recherche de vecteurs (embeddings)
RAG	Retrieval-Augmented Generation — enrichir les réponses IA avec des documents réels (polices Groupama)
HNSW	Hierarchical Navigable Small World — algorithme d'index vectoriel pour la recherche approximative rapide
Persona	Workflow métier avec ses propres prompts, polices de référence et interface adaptée
Customer 360	Vue unifiée d'un client agrégeant toutes les interactions à travers les personas
Container Apps	Service Azure pour héberger des containers Docker sans gérer l'infrastructure